Universidad Tecmilenio

Recomendador documental Top-5
Caso académico Softtek

Isaac Esquivel Ruiz
Sistemas y tecnologías de administración del conocimiento

Objetivo y conjunto de documentos

Implementé un recomendador que recupera documentos relacionados con un ID o una consulta breve. El corpus contiene 30 textos ficticios sobre accesos, respaldos, despliegues, seguridad y rendimiento. Incluye diez políticas o procesos, diez incidentes y diez guías operativas. Softtek es la referencia del contexto; los documentos no representan información interna real de la empresa.

Enfoque y funcionamiento

Elegí TF-IDF por su sencillez y porque permite explicar la comparación. El programa une título y contenido, convierte a minúsculas, normaliza tildes y retira símbolos y algunas palabras frecuentes. Usa palabras y pares de palabras, frecuencia sublineal y normalización L2. Las categorías no intervienen en la puntuación.

La matriz TF-IDF tiene 30 filas y 1488 características. Se calcula una matriz de similitud coseno de 30 × 30. Para una consulta nueva se utiliza el mismo vocabulario. El sistema ordena las coincidencias, excluye la semilla y devuelve hasta cinco puntuaciones positivas. Si la consulta no comparte términos, informa que no hay resultados. El score mide parecido léxico, no probabilidad de resolución.

Pruebas y resultados

Prueba / entrada	Primer resultado	Coseno	P@5
1. Política: DOC001	DOC002 - Ticket: cuenta bloqueada en el portal	0.1407	1.00
2. Incidente: DOC008	DOC012 - Bitácora de pruebas de recuperación	0.0909	0.80
3. Texto sobre despliegue y rollback	DOC013 - Política de despliegue y reversión de versiones	0.3505	1.00

Las tres pruebas generaron un Top-5. La precisión temática media fue 0.9333, calculada con conjuntos relevantes definidos por tema antes de ejecutar. La segunda prueba recuperó cuatro documentos de respaldos y un ticket de cuenta bloqueada, DOC002, con score 0.055285. Palabras genéricas compartidas explican ese resultado ajeno. Las salidas completas y sus comentarios están en la carpeta evidencias.

Los controles verificaron exclusión de la semilla, orden, repetibilidad y manejo de entradas inválidas o fuera del vocabulario. El notebook se ejecutó localmente en orden, y el script registró versiones, parámetros y la huella del corpus.

Utilidad y oportunidades de mejora

Utilidad organizacional

El recomendador puede evitar que un técnico busque desde cero una solución que otro equipo ya documentó. Una política puede llevar a un ejemplo de aplicación y un incidente a guías de recuperación. Esto podría reducir consultas repetidas y acelerar la revisión de opciones. El sistema no ejecuta acciones ni sustituye la autorización y el juicio del especialista.

En esta práctica no medí tiempos de atención ni ahorros económicos. Para comprobar el beneficio realizaría un piloto comparando la búsqueda habitual con el recomendador, usando tareas equivalentes y registrando tiempo, pertinencia y resolución correcta.

Límites observados

La segunda prueba muestra que la coincidencia de palabras puede introducir documentos poco útiles. TF-IDF también puede fallar con sinónimos, abreviaturas, ambigüedad y documentos cortos. Normalizar tildes no unifica todas las variantes de una palabra. Los pares de términos tampoco garantizan interpretar correctamente una negación.

El corpus está equilibrado y organizado en cinco temas claros, por lo que favorece una demostración controlada. Tres pruebas y una evaluación temática del autor no bastan para generalizar. Un documento del tema correcto puede seguir siendo inadecuado por versión, sistema o causa del incidente. La P@5 presentada no equivale a exactitud de una solución.

Mejoras para un entorno real

Contexto y vigencia: agregar sistema afectado, versión, responsable y fecha de revisión. Permitir filtros temáticos para reducir resultados ajenos.

Acceso y seguridad: aplicar permisos por rol antes de mostrar resultados y registrar el acceso a documentación sensible. Mantener separados los datos de cada cliente.

Recuperación y escala: comparar TF-IDF con embeddings o una búsqueda híbrida. Para más documentos, calcular similitud por consulta en lugar de almacenar toda la matriz entre pares.

Evaluación continua: ampliar consultas reales, usar juicios de especialistas y medir P@5, utilidad y tiempo de búsqueda. Revisar falsos positivos y contenidos obsoletos periódicamente.

Reflexión organizacional en video

Enlace: pendiente de grabación y publicación. La consigna exige un video de máximo cinco minutos. Se incluye Guion_reflexion.md como apoyo. El enlace accesible para el docente debe incorporarse aquí antes de la entrega; el guion no sustituye la grabación.

Conclusión

La implementación demuestra recomendaciones reproducibles y deja visible un error de recuperación. Su valor inicial está en acercar conocimiento relacionado; para utilizarlo en una organización todavía necesita controles de acceso, documentos vigentes y evaluación con usuarios reales.